

Soluções - Redes Neurais Artificiais: Princípios e prática

Capítulo 1 - Introdução

1 Modelos de um neurônio

Pré-requisitos: Funções, Limites*, Derivadas

1.1. Um exemplo de função logística é definida por

$$\varphi(v) = \frac{1}{1 + \exp(-av)}$$

cujos valores limites são 0 e 1. Mostre que a derivada de $\varphi(v)$ em relação a v é dada por

$$\frac{d\varphi}{dv} = a\varphi(v)[1 - \varphi(v)]$$

Qual é o valor desta derivada na origem?

Solução:

Para resolver podemos utilizar a regra da cadeia. Tomando a substituição com $u(v) = 1 + e^{-av}$, sabemos que $u'(v) = -ae^{-av}$. Portanto temos:

$$\varphi(v) = \frac{1}{u(v)} = u^{-1}(v) \implies \varphi'(v) = -u^{-2}(v)u'(v)$$

$$\varphi'(v) = \frac{ae^{-av}}{1 + e^{-av}} = ae^{-av}\varphi^2(v)$$

Podemos isolar e^{-av} em função de $\varphi(v)$:

$$e^{-av} = \frac{1}{\varphi(v)} - 1 = \frac{1 - \varphi(v)}{\varphi(v)}$$

E por fim:

$$\frac{d\varphi}{dv}(v) = \frac{a\varphi^2(v)[1 - \varphi(v)]}{\varphi(v)} \implies \frac{d\varphi}{dv}(v) = a\varphi(v)[1 - \varphi(v)]$$

Para calcular o valor da derivada na origem basta calcular: $\varphi(0) = \frac{1}{1 + e^{-a \cdot 0}} = \frac{1}{2}$. E aplicando na derivada:


$$\frac{d\varphi}{dv}(0) = a\varphi(0)[1 - \varphi(0)] \implies \frac{d\varphi}{dv}(0) = \frac{a}{4}$$

Para criar um esboço da função podemos tomar os seguintes limites:

$$\lim_{v \rightarrow +\infty} \varphi(v) = \lim_{v \rightarrow +\infty} \frac{1}{1 + e^{-av}}, \lim_{v \rightarrow +\infty} e^{-av} = 0 \implies \lim_{v \rightarrow +\infty} \varphi(v) = 1$$

$$\lim_{v \rightarrow -\infty} \varphi(v) = \lim_{v \rightarrow -\infty} \frac{1}{1 + e^{-av}}, \lim_{v \rightarrow -\infty} e^{-av} = \infty \implies \lim_{v \rightarrow -\infty} \varphi(v) = 0$$

Portanto, o gráfico da função é:



1.2. Uma função sigmóide ímpar é definida por

$$\varphi(v) = \frac{1 - \exp(-av)}{1 + \exp(-av)} = \tanh\left(\frac{av}{2}\right)$$

onde $\tanh$ representa a tangente hiperbólica. Os valores limites desta segunda função sigmóide são -1 e $+1$. Mostre que a derivada de $\varphi(v)$ em relação a v é dada por

$$\frac{d\varphi}{dv} = \frac{a}{2} [1 - \varphi^2(v)]$$

Qual é valor desta derivada na origem? Suponha que o parâmetro de inclinação a seja infinitamente grande. Qual é a forma resultante de $\varphi(v)$?

Solução:

Podemos resolver utilizando a derivada da divisão, a regra da cadeia e o quadrado da soma. Aplicando temos:

$$\varphi'(v) = \frac{ae^{-av}(1 + e^{-av}) + ae^{-av}(1 - e^{-av})}{(1 + e^{-av})^2} = a \frac{a[]}{(1 + e^{-av})^2}$$

1.3. Uma outra função sigmóide ímpar é a sigmóide algébrica:

$$\varphi(v) = \frac{v}{\sqrt{1 + v^2}}$$

cujos valores limites são -1 e $+1$. Mostre que a derivada de $\varphi(v)$ em relação a v é dada por

$$\frac{d\varphi}{dv} = \frac{\varphi^3(v)}{v^3}$$

Qual é o valor desta derivada na origem?

1.4. Considere as duas seguintes funções:


(i) $\varphi(v) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \exp\left(-\frac{x^2}{2}\right) dx$

(ii) $\varphi(v) = \frac{2}{\pi} \tan^{-1}(v)$

Explique por que estas funções satisfazem os requisitos de uma função sigmóide. De que modo estas duas funções diferem entre si?

1.5. Qual das cinco funções sigmóides descritas nos Problemas 1.1 a 1.4 seria qualificada como uma função de distribuição (de probabilidade) cumulativa? Justifique a sua resposta.


1.6. Considere a função de ativação pseudolinear $\varphi(v)$ mostrada na Fig. P1.6.



a) Formule $\varphi(v)$ como uma função de v .

b) O que acontece com $\varphi(v)$ se a aproximar-se de zero?

1.7. Repita o Problema 1.6 para a função de ativação pseudolinear $\varphi(v)$ mostrada na Fig. P1.7.



1.8. Um neurônio tem uma função de ativação $\varphi(v)$ definida pela função logística do problema 1.1, onde v é o campo local induzido, e o parâmetro de inclinação a está disponível para ajustes. Considere que $x_1, x_2, \dots, x_m$, representem os sinais de entrada aplicados aos nós de fonte do neurônio e que b represente o bias. Por conveniência de representação, podemos fazer com que o parâmetro de inclinação a seja absorvido pelo campo local induzido v , escrevendo

$$\varphi(v) = \frac{1}{1 + \exp(-v)}$$

Como você modificaria as entradas $x_1, x_2, \dots, x_m$ de forma a produzir a mesma saída de antes? Justifique a sua resposta.

1.9. Um neurônio j recebe entradas de quatro outros neurônios cujos níveis de ativação são 10, -20, 4, -2. Os respectivos pesos sinápticos do neurônio j são 0.8, 0.2, -1.0 e -0.9. Calcule a saída do neurônio j para as duas seguintes situações:

(a) O neurônio é linear

(b) O neurônio é representado por um modelo de McCulloch-Pitts.

Assuma que o bias aplicado ao neurônio é zero.

1.10. Repita o Problema 1.9 para um modelo de neurônio baseado na função logística

$$\varphi(v) = \frac{1}{1 + \exp(-v)}$$


1.11.

- (a) Mostre que o modelo formal de McCulloch-Pitts de um neurônio pode ser aproximado por um neurônio sigmóide (i.e., um neurônio que utiliza uma função de ativação sigmóide) com pesos sinápticos grandes.
- (b) Mostre que o neurônio linear pode ser aproximado por um neurônio sigmóide com pesos sinápticos pequenos.

2 Arquitetura de rede

1.12. Uma rede alimentada adiante totalmente conectada tem 10 nós de fonte, 2 camadas ocultas, uma com 4 neurônios e a outra com 3 neurônios em um único neurônio de saída. Construa um grafo arquitetural desta rede.

1.13.




- (a) A Figura 1.13 mostra um grafo de fluxo de sinal de uma rede 2-2-2-1 alimentada adiante. A função $\varphi(\cdot)$ representa uma função logística. Escreva o mapeamento de entrada-saída definido por esta rede.
- (b) Suponha que o neurônio de saída do grafo de fluxo de sinal da Fig. P1.13 opere na sua região linear. Escreva o mapeamento de entrada-saída definido por esta nova rede.

1.14. A rede descrita na Fig. P1.13 não tem bias. Suponha que bias iguais a -1 e $+1$ sejam aplicados aos neurônios superior e inferior da primeira camada oculta, e bias iguais a $+1$ e -2 sejam aplicados aos neurônios superior e inferior da segunda camada oculta, respectivamente. Escreva a nova forma do mapeamento de entrada-saída definido pela rede.


1.15. Considere uma rede de múltiplas camadas alimentada adiante, na qual todos os neurônios operam nas suas regiões lineares. Justifique a afirmação de que esta rede é equivalente a uma rede alimentada adiante de camada única.

1.16. Construa uma rede totalmente recorrente com 5 neurônios, mas sem auto-realimentação.

1.17. A Figura P1.17 mostra um grafo de fluxo de sinal de uma rede recorrente constituída de dois neurônios. Escreva a equação de diferenças não-linear que define a evolução de $x_1(n)$ ou de $x_2(n)$. Estas duas variáveis definem as saídas dos neurônios superior e inferior, respectivamente. Qual é a ordem desta equação?



1.18. A Figura P1.18 mostra o grafo de fluxo de sinal de uma rede recorrente que consiste de dois neurônios com auto-realimentação. Escreva o sistema acoplado de duas equações de diferenças de primeira ordem que descrevem a operação do sistema.



1.19. Uma rede recorrente tem 3 nós de fonte, 2 neurônios ocultos e 4 neurônios de saída. Construa um grafo arquitetural que descreva esta rede.

2 Representação do conhecimento

1.20. Uma forma útil de pré-processamento se baseia no modelo auto-regressivo (AR) descrito pela equação de diferenças (para dados de valores reais)

$$y(n) = w_1 y(n-1) + w_2 y(n-2) + \dots + w_M y(n-M) + v(n)$$

onde $y(n)$ é a saída do modelo; $v(n)$ é uma amostra retirada de um processo de ruído branco com média zero e uma variância predefinida; $w_1, w_2, \dots, w_M$, são os coeficientes do modelo AR; e M é a ordem do modelo. Mostre que o uso deste modelo fornece duas formas de invariância geométrica: (a) em escala e (b) em translação temporal. Como estas duas invariâncias poderiam ser utilizadas em redes neurais?

1.21. Considere que $\mathbf{x}$ seja um vetor de entrada e que $\mathbf{s}(\alpha, \mathbf{x})$ seja um operador de transformação agindo sobre $\mathbf{x}$ e dependente de um parâmetro α . O operador $\mathbf{s}(\alpha, \mathbf{x})$ satisfaz dois requisitos:

- $\mathbf{s}(0, \mathbf{x}) = 0$
- $\mathbf{s}(0, \mathbf{x})$ é diferenciável em relação a α .

O vetor tangente é definido pela derivada parcial $\partial \mathbf{s}(\alpha, \mathbf{x}) / \partial \alpha$ (Simard et al., 1992). Suponha que $\mathbf{x}$ represente uma imagem e que α seja um parâmetro de rotação. Como você calcularia o vetor tangente para o caso em que α é pequeno? O vetor tangente é localmente invariante em relação à rotação da imagem original; por quê?